

ANALISIS DATA ENGINEERING

Arsitektur Data Pipeline & Medallion

Studi Kasus Repositori [hanskoetjing/datapipeline-training](https://github.com/hanskoetjing/datapipeline-training) Menggunakan Apache Airflow, Python & SQL Marts

Alur & Orchestration Pipeline

Penjelasan eksekusi skrip Python dalam Apache Airflow serta alur
kerja ETL dari Ingestion hingga Analytics

Orkestrasi DAG Apache Airflow



1. File Ingestion DAGs

Airflow mengeksekusi DAG khusus seperti `load_customers_from_file.py`, `load_orders_from_file.py`, dan `load_products_from_file.py` untuk membaca file mentah secara teratur dan konsisten.



2. Processing & Cleansing

Setiap DAG memicu skrip Python dan SQL pendukung seperti `func_clean_numeric.sql` untuk memvalidasi tipe data, menangani error, dan memisahkan baris bermasalah ke tabel `rejected`.

Alur Data End-to-End



Otomatisasi & Kontrol Kualitas

Pipeline dibangun dari landing zone hingga pembentukan mart dengan kontrol dependensi otomatis di Airflow.

Data mentah ditangkap dari berkas eksternal, dibersihkan melalui validasi numerik, lalu disajikan dalam bentuk SQL Views yang siap dikonsumsi oleh aplikasi analitik.



Medallion Architecture

Penerapan konsep perbaikan data bertahap dari Bronze Layer (Raw)
hingga Silver Layer (Cleaned)

Bronze Layer: Ingestion & Raw Data




Penyimpanan As-Is: Menampung data mentah persis sesuai format asli dari file sumber tanpa transformasi berlebih.



Flexibility Format: Menggunakan tipe data longgar seperti VARCHAR/TEXT agar pipeline tidak terhenti saat format berubah.



Rejected Data Audit: Dilengkapi tabel `create_rejected_data_bronze.sql` untuk menangkap data berformat cacat/invalid.



Silver Layer: Cleansed Data



Schema Enforcement: Penerapan tipe data ketat seperti INTEGER, NUMERIC, dan TIMESTAMP.



Audit Timestamp: Setiap tabel Silver dilengkapi kolom modified (TIMESTAMP WITHOUT TIME ZONE) di posisi terakhir.



Data Cleaning: Menggunakan fungsi SQL func_clean_numeric.sql untuk menjamin integritas nilai angka.

Column Name	#	Data type	Identity	Collation	Not Null	Default	Co
A-Z category_id	1	varchar(6)		default	[V]		
A-Z category_name	2	varchar(100)		default	[]		
modified	3	timestamp			[V]	CURRENT_TIMESTAMP	

field modified sebagai audit timestamp



Datamart & Analytical Views

Penyajian data Gold Layer berbasis SQL View untuk kebutuhan
pelaporan bisnis dan operasional

Rincian Datamart Views



Pending Payments

Menggabungkan data orders, payments, dan customers untuk melacak transaksi pesanan yang status pembayarannya belum tuntas.



Sum Products Ordered

Agregasi volume penjualan dan total kuantitas per produk dari tabel orders, order_items, dan products.



Sum Categories Ordered

Agregasi tingkat tinggi untuk menghitung performa pendapatan dan tren pemesanan berdasarkan kategori produk.

Penggunaan Datamart oleh Tim Bisnis

Nama View SQL	Target Pengguna Utama	Kasus Penggunaan (Use Cases)
pending_payments_mart	Finance / Account Receivable	Follow-up penagihan pembayaran pelanggan & penentuan SLA penyelesaian transaksi.
sum_products_ordered	Inventory & Sales Analyst	Analisis produk best-seller vs slow-moving serta optimalisasi persediaan stok.
sum_categories_ordered	Executive Management & Marketing	Penilaian kontribusi omset per kategori & alokasi budget kampanye promosi.

Manfaat Arsitektur Data

100%

Auditability & Traceability

Keunggulan Utama Pipeline

Separation of Concerns: Pemisahan lapisan Bronze, Silver, dan Mart mencegah pencampuran logika bisnis dengan proses ingesti data mentah.

Replayability: Jika terjadi perubahan aturan bisnis di masa depan, data Silver dan Mart dapat dibangun ulang (*re-run*) langsung dari Bronze tanpa mengambil ulang data dari sistem sumber.

Image Sources



<https://montecarlo.ai/wp-content/uploads/2023/07/what-is-data-pipeline-architecture.webp>

Source: montecarlo.ai



https://assets.qlik.com/image/upload/f_auto/q_auto/v1702401035/qlik/glossary/data-ingestion/seo-hero-data-ingestion_hfnzuo.jpg

Source: www.qlik.com



<https://www.6sigma.us/wp-content/uploads/2024/12/data-quality-assurance-process-1024x900.webp>

Source: www.6sigma.us

DIMENSIONAL MODELING

Analisis Star Schema Datamart Views

Penjelasan Rinci Struktur Fact Table & Dimension Tables pada Gold Layer Repositori
datapipeline-training

Konsep Dasar Star Schema



Fact Tables (Tabel Fakta)

Pusat Pemodelan: Berisi peristiwa bisnis atau transaksi kuantitatif (*measures/metrics*) seperti nilai total, kuantitas terjual, dan saldo.

Penyambung Dimensi: Menyimpan *foreign keys* yang terhubung langsung ke tabel-tabel dimensi pendukung.



Dimension Tables (Tabel Dimensi)

Konteks Deskriptif: Menyediakan atribut konteks bisnis (*who, what, where, when*) untuk memfilter dan mengelompokkan data.


Atribut OLAP: Mengatur granularitas analitik (misal: nama pelanggan, wilayah toko, kategori produk).

Arsitektur Dimensional

Transformasi Silver ke Gold Layer

Data bersih dari Silver Layer dirangkai menjadi struktur Star Schema dalam bentuk SQL Views di Gold Layer.

Pendekatan ini mengoptimalkan query OLAP dan memudahkan integrasi dengan BI tools seperti Tableau, Power BI, atau Metabase tanpa meruplikasi penyimpanan fisik.



1. View: pending_payments_mart

Fact Order Payments

Granularitas: Transaksi pemesanan dengan status penagihan pending.

Key Metrics: `total\_amount`, `amount\_paid`, serta nilai tunggakan/piutang (`total\_amount - amount\_paid`).

Keys: `customer\_id`, `store\_id`, `payment\_id`.

Dimension Tables

Dim Customer (`customers\_silver`): Memberikan konteks siapa pelanggan yang menunggu (`first\_name`, `email`, `phone`).

Dim Payment Status (`payments\_silver`): Memfilter transaksi yang bernilai `payment\_status = 'pending'`.

Dim Date: Digunakan untuk analisis umur piutang (*aging analysis*).

2. View: sum_products_ordered



Fact Order Items: Granularitas tingkat rincian barang per pesanan (``order_items_silver` JOIN `orders_silver``).




Measures: Total kuantitas terjual (``SUM(quantity)``), total pendapatan (``SUM(quantity * unit_price)``), dan frekuensi transaksi (``COUNT(order_id)``).



Dim Product (``products_silver``): Memberikan atribut deskriptif seperti ``product_name``, ``sku``, dan harga standar.



Dim Store (``stores_silver``): Menyediakan atribut lokasi cabang toko tempat penjualan terjadi.



3. View: sum_categories_ordered




Fact Category Sales

Agregasi penjualan tingkat tinggi (*high-level summary*) yang menggabungkan seluruh item berdasarkan kategori produk.



Dim Category

Tabel dimensi utama (`categories\_silver`) yang berisi `category\_name` dan `description` sebagai basis `GROUP BY`.



Agregat Metrik

Menghitung total volume barang terjual (`SUM(quantity)`), total omset kategori, dan jumlah item unik yang laku.

Matriks Ringkasan Star Schema

Nama View Mart	Fact Table (Granularitas)	Tabel Dimensi Utama	Utama Metrik / Measures
`pending_payments_mart`	Transaksi Pesanan Unpaid (`orders` + `payments`)	`customers_silver`, `payments_silver`	Total Tagihan, Nilai Terbayar, Sisa Piutang
`sum_products_ordered`	Item Produk per Order (`order_items_silver`)	`products_silver`, `stores_silver`	Total Kuantitas Terjual, Total Revenue Produk
`sum_categories_ordered`	Agregasi per Kategori (`categories` + `products`)	`categories_silver`, `products_silver`	Total Volume Kategori, Total Pendapatan Kategori

Keunggulan Pemodelan Dimensional

10x

Efisiensi Query & Analytics

Mengapa Menggunakan Star Schema?

Query Simplification: Mengurangi kompulsi *JOIN* rumit di level aplikasi analitik dengan menyediakannya secara terstruktur via SQL Views.

BI Tools Integration: Struktur Fact-Dimension memudahkan *drag-and-drop* pembuatan dashboard pada tools seperti Tableau dan Power BI.

Single Source of Truth: Menjamin konsistensi metrik keuangan, produk, dan penjualan di seluruh departemen.